

SIMPLON MAGHREB

Formation Data Analyst — Promotion 2025-2026

RAPPORT DE PROJET FIL ROUGE

Analyse Comparative des Pays pour l'Investissement et la Qualite de Vie



Realisee par : Hajar Mamdouh

Formateur : Yassine

Date de soutenance : Mars 2026

GitHub : github.com/hajarmamdouh/fil-rouge-investissement

Resume Executif

Ce rapport presente le projet fil rouge realise dans le cadre de la formation Data Analyst chez Simplon Maghreb. L'objectif est de construire un pipeline de donnees complet — de la collecte automatisee jusqu'au dashboard interactif — permettant de comparer 169 pays selon leurs indicateurs economiques, sociaux et de qualite de vie sur 10 ans (2015-2024).

La problematique centrale est la suivante : comment identifier objectivement les pays les plus attractifs pour l'investissement et les mieux adaptes a une installation durable, en s'appuyant sur des donnees multicriteres fiables et actualisees ?

Indicateur cle	Valeur
Nombre de pays analyses	169 pays
Periode couverte	2015 – 2024 (10 ans)
Nombre d'indicateurs par pays/annee	21 indicateurs
Lignes dans la base de donnees	1 222 lignes
Sources de donnees	World Bank API + World Happiness Report
Technologies utilisees	Python · PostgreSQL · Power BI · Git
Pays le plus heureux (2024)	Finland — Score 7,84/10
PIB moyen mondial	18 053 USD par habitant
Score attractivite moyen	0,53 / 1,00
Impact Covid sur le bonheur	+0,11 (leger mieux post-covid)

Table des Matieres

Section	Titre	Page
1	Introduction et Contexte	4
2	Architecture Technique et Technologies	5
3	Sources de Donnees	6
4	Pipeline ETL — De la Collecte au Stockage	7
5	Modelisation — Schema en Etoile	9
6	Exploration des Donnees Brutes (EDA 1)	11
7	Nettoyage et Preparation des Donnees	12
8	Analyse Exploratoire Post-Nettoyage (EDA 2)	13
9	Analyse Statistique — Tests et Resultats	15
10	Clustering K-Means — Machine Learning	17
11	Dashboard Power BI — Les 4 Pages	19
12	Resultats et Insights Cles	24
13	Limites et Ameliorations Futures	25
14	Conclusion	26
Annexes	Glossaire, Technologies, Liens	27

1. Introduction et Contexte du Projet

1.1 Contexte

Dans un monde globalise, le choix d'un pays pour investir, s'etablir ou envoyer des employes en mobilite est une decision strategique majeure. Les investisseurs, les particuliers, les entreprises et les analystes ont besoin d'outils fiables pour comparer les pays de maniere objective, multidimensionnelle et basee sur des donnees reelles.

Ce projet propose une solution analytique complete qui agrege, nettoie et visualise des donnees provenant de deux sources internationales reconnues : la Banque Mondiale et le World Happiness Report, sur une periode de 10 ans couvrant les phases pre- et post-pandemie Covid-19.

1.2 Problematique

Comment identifier, a partir de donnees objectives et multicriteres, les pays les plus attractifs pour l'investissement et ceux offrant la meilleure qualite de vie, en tenant compte des dimensions economiques, sociales, de liberte et de bien-etre sur la periode 2015-2024 ?

1.3 Objectifs Specifiques

- Construire un pipeline ETL complet automatise de la collecte a la visualisation
- Modeliser une base de donnees PostgreSQL en schema en etoile (Data Warehouse)
- Analyser statistiquement les correlations entre les indicateurs (ANOVA, Pearson, Kruskal-Wallis)
- Appliquer le clustering K-Means pour segmenter les pays en groupes homogenes
- Produire un dashboard Power BI interactif a destination de 4 profils d'utilisateurs

1.4 Profils Utilisateurs Cibles


Profil	Besoin principal	Page dashboard
Investisseurs	Identifier les pays les plus rentables et stables economiquement	Page 1 — Investisseurs
Particuliers	Trouver le meilleur pays pour vivre selon la qualite de vie	Page 2 — Qualite de Vie
Entreprises RH	Comparer les pays pour la mobilite internationale des employes	Page 3 — Mobilite RH
Analystes	Explorer les correlations, tendances et clusters de pays	Page 4 — Analyses

2. Architecture Technique et Technologies

2.1 Stack Technologique

Couche	Technologie	Version	Role
Collecte	Python + wldata + requests	3.14	Appels API World Bank et WHR
Traitement	Pandas + NumPy + Scikit-learn	2.x / 1.x	Nettoyage, fusion, ML
Statistiques	Scipy + Statsmodels	1.x	Tests ANOVA, Pearson, Shapiro
Stockage	PostgreSQL 18	18	Base de donnees relationnelle
ORM	SQLAlchemy	2.x	Interface Python-PostgreSQL
Visualisation	Power BI Desktop	Latest	Dashboard interactif 4 pages
IDE	VS Code + Jupyter	Latest	Developpement et analyse
Versioning	Git + GitHub	Latest	Gestion du code source
Gestion projet	Jira + Confluence	Cloud	Kanban et documentation

2.2 Architecture Globale du Pipeline



Le pipeline suit une architecture lineaire en 5 etapes sequentielles : Collecte → Nettoyage → Stockage → Analyse → Visualisation. Chaque etape est implementee dans un script Python dedie avec gestion des erreurs et validation de la qualite des donnees.

2.3 Structure du Projet GitHub

Dossier / Fichier	Contenu
src/	Scripts Python ETL (collecte, nettoyage, chargement, corrections)
notebooks/	Analyses Jupyter : EDA brute, EDA post-nettoyage, clustering, statistiques
data/raw/	Donnees brutes collectees depuis les APIs (CSV)
data/final/	Donnees nettoyees et pret a l'emploi (master_clean.csv, clusters.csv)
reports/plots/	Graphiques generes automatiquement par les notebooks
sql/	Scripts SQL de creation du schema PostgreSQL
README.md	Documentation complete du projet
.github/	Configuration Git et workflows

3. Sources de Donnees

3.1 World Bank API

La Banque Mondiale fournit des donnees macroeconomiques et sociales gratuitement via une API REST publique accessible avec la librairie Python wbdata. Nous avons collecte 8 indicateurs pour 217 pays sur 2015-2024.

Indicateur	Code World Bank	Description	Completude
PIB par habitant	NY.GDP.PCAP.CD	Richesse produite par personne (USD)	100%
Croissance PIB	NY.GDP.MKTP.KD.ZG	Taux de croissance annuel (%)	100%
Inflation	FP.CPI.TOTL.ZG	Variation prix a la consommation (%)	100%
Population	SP.POP.TOTL	Nombre total d'habitants	100%
RNB/habitant	NY.GNP.PCAP.CD	Revenu National Brut/habitant (USD)	100%
Taux chomage	SL.UEM.TOTL.ZS	% actifs sans emploi (WHR)	87%
Esperance de vie	SP.DYN.LE00.IN	Esperance de vie a la naissance	100%
Taux alphabetisation	SE.ADT.LITR.ZS	% adultes sachant lire	100%

3.2 World Happiness Report (WHR)

Le World Happiness Report est une etude annuelle publiee par l'ONU depuis 2012, basee sur des sondages Gallup aupres de 1 000 personnes par pays. Deux fichiers CSV ont ete collectes et fusionnes : 2015-2020 et 2021.


Indicateur WHR	Description	Echelle	Interpretation
Score bonheur	Satisfaction de vie globale (Life Ladder)	0 a 10	Plus c'est eleve, mieux c'est
Soutien social	Avoir quelqu'un sur qui compter	0 a 1	1 = tres fort soutien
Liberte	Liberte de faire ses propres choix	0 a 1	1 = tres libre
Generosite	Dons a des oeuvres caritatives	-1 a 1	Peut etre negatif (normal)
Corruption	Perception de la corruption publique	0 a 1	0 = peu corrompu
Emotions positives	Frequence bonheur, rire, plaisir	0 a 1	1 = tres positif
Emotions negatives	Frequence tristesse, colere, stress	0 a 1	0 = tres positif

3.3 Limites des Sources de Données

- Le WHR ne couvre pas tous les pays (ex: Maroc absent sur certaines années)
- Le taux de chômage est absent pour les micro-territoires (Gibraltar, Isle of Man, etc.) — 13% de valeurs manquantes
- L'API World Bank genere des timeouts occasionnels — traites par des scripts de correction dedies
- L'inflation 2015 a ete imputee par mediane regionale suite a des echecs de collecte API

4. Pipeline ETL — De la Collecte au Stockage

4.1 Vue d'ensemble



4.2 Etape 1 — Collecte World Bank (01_collecte_worldbank.py)

Ce script appelle l'API World Bank pour chaque indicateur et chaque année de 2015 à 2024. Il gère les timeouts avec un mécanisme de retry, et sauvegarde chaque indicateur dans un fichier CSV séparé dans data/raw/.

- Resultat : worldbank_merged.csv — 1 222 lignes, 169 pays
- Correction complémentaire : fix_unemployment2.py — récupération du taux de chômage via l'API directe World Bank avec correspondance par codes ISO3

4.3 Etape 2 — Collecte WHR (02_collecte_happiness.py)

Ce script charge les deux fichiers CSV du World Happiness Report (2015-2020 et 2021), harmonise les noms de colonnes qui diffèrent entre les éditions annuelles, et fusionne les données en un fichier unique.

- Resultat : happiness_all_years.csv — 962 lignes, 157 pays, 2015-2021

4.4 Etape 3 — Nettoyage et Fusion (03_nettoyage_fusion.py)

C'est l'etape la plus complexe du pipeline. Elle effectue le mapping des codes ISO3, la fusion des deux sources et le calcul du score d'attractivite composite.

Sous-etape	Action	Resultat
Mapping ISO3	Dictionnaire 150+ correspondances pays WHR -> ISO3	Harmonisation des cles de jointure
Fusion	Jointure World Bank + WHR sur (country_code, year)	master_dataset.csv — 1222 lignes
Score attractivite	MinMaxScaler sur 8 indicateurs cles	Colonne attractivity_score (0 a 1)
Export	Sauvegarde CSV et chargement BDD	master_dataset.csv — 21 colonnes

4.5 Etape 4 — Traitement Valeurs Manquantes (05_traitement_null.py)

5 methodes de traitement en cascade selon la nature de chaque indicateur :

Methode	Indicateurs concernes	Logique
Interpolation lineaire	Bonheur, liberte, corruption, soutien social	Par pays, dans le temps (preserves la tendance)
Forward/Backward fill	PIB, population, alphabetisation	Propager la derniere valeur connue du pays
Moyenne regionale	Inflation, esperance de vie	Par region geographique et par annee
Moyenne mondiale	Dernier recours general	Par annee si pas de donnee regionale
Mediane globale	Cas extremes residuels	Valeur centrale globale de l'indicateur

Resultat final : master_clean.csv — 1 222 lignes, 22 colonnes, ZERO valeur manquante sur les colonnes numeriques cles.

4.6 Etape 5 — Chargement PostgreSQL (04_chargement_postgresql.py)

Ce script charge les données dans la base PostgreSQL en respectant l'ordre des contraintes de clés étrangères. Il inclut des tests de qualité automatiques exécutés directement via des vues SQL.


- 0 doublon détecté sur la clé (country_code, year)
- 0 valeur aberrante détectée sur les colonnes numériques clés
- 4 vues analytiques créées : v_analyse_complete, v_evolution_temporelle, v_matrice_pib_bonheur, v_stats_region
-

5. Modelisation — Schema en Etoile

5.1 Principe

Le schéma en étoile est le modèle de référence pour les entrepôts de données analytiques (Data Warehouse). Il organise les données autour d'une table de faits centrale contenant les mesures numériques, entourée de tables de dimensions contenant les attributs descriptifs. Ce modèle optimise les performances des requêtes analytiques et facilite la création de rapports dans Power BI.

5.2 Diagramme du Schema en Etoile



5.3 Description des Tables

Table	Type	Lignes	Cle primaire	Role
fact_indicateurs	Faits	1 222	fact_id	Toutes les mesures numeriques par pays et annee
dim_pays	Dimension	169	Code_pays (ISO3)	Informations geographiques et administratives
dim_annee	Dimension	10	Annee	Informations temporelles et periode Covid
dim_region	Dimension	7	ID_region	7 grandes regions geographiques World Bank
dim_income_level	Dimension	5	ID_niveau_revenu	5 categories de revenu selon seuils World Bank

5.4 Relations entre Tables

Table source (1)	Colonne	Table cible (*)	Type de relation
dim_pays	Code_pays	fact_indicateurs	Un-a-plusieurs : 1 pays -> N mesures annuelles
dim_annee	Annee	fact_indicateurs	Un-a-plusieurs : 1 annee -> N mesures par pays
dim_region	ID_region	dim_pays	Un-a-plusieurs : 1 region -> N pays
dim_income_level	ID_niveau_revenu	dim_pays	Un-a-plusieurs : 1 niveau -> N pays

5.5 Vues Analytiques SQL

4 vues SQL ont ete creees au-dessus du schema en etoile pour faciliter l'analyse dans Power BI sans avoir a recreer les jointures complexes :

Vue	Jointures effectuees	Colonnes calculees	Utilisee dans Power BI pour
v_analyse_complete	fact + dim_pays + dim_region + dim_income_level + dim_annee	rank_bonheur, rank_attractivite, rank_pib	Toutes les pages du dashboard
v_matrice_pib_bonheur	fact + dim_pays + dim_region + dim_income_level	tranche_pib, categorie_bonheur	Page 4 — Scatter PIB vs Bonheur
v_evolution_temporelle	fact + dim_pays + dim_annee	happiness_prev, variation_bonheur, tendance	Page 4 — Courbes temporelles
v_stats_region	fact + dim_region	Agregats par region et annee	Page 1 et 3 — Comparaisons regions

6. Exploration des Donnees Brutes (EDA 1)


6.1 Objectif



L'exploration des donnees brutes (notebook 00_eda_exploration_brute.ipynb) a ete realisee AVANT tout nettoyage, conformément a la methodologie standard du data analyst. Cette etape permet d'identifier les problemes de qualite et de planifier les actions de nettoyage necessaires.

6.2 Rapport Qualite Donnees Brutes

Indicateur	Statut	Completude	Probleme identifie
PIB par habitant	OK	100%	Distribution log-normale coherente
Score de bonheur	OK	100%	Valeurs entre 2,3 et 7,9 — cohrent
Taux de chomage	CRITIQUE	0%	Timeouts API World Bank — script de correction cree
Inflation 2015	MOYEN	Partiel	Valeurs aberrantes negatives — imputation mediane
Esperance de vie	MOYEN	Partiel	Donnees partielles certains pays — imputation
Doublons	OK	N/A	0 doublon sur la cle (country_code, year)
Types de donnees	OK	N/A	Colonnes numeriques correctement typees

6.3 Visualisations EDA Brute





7. Nettoyage et Preparation des Donnees

7.1 Actions de Nettoyage Realisees

Action	Script	Impact
Recuperation taux chomage	fix_unemployment2.py	1 072 valeurs ajoutees (87% completude)
Mapping pays WHR -> ISO3	03_nettoyage_fusion.py	157 pays harmonises avec codes ISO3
Interpolation lineaire bonheur	05_traitement_null.py	Tendances preservees par pays
Imputation inflation par region	05_traitement_null.py	Mediane regionale par annee
Calcul score attractivite	03_nettoyage_fusion.py	Composite MinMaxScaler 8 indicateurs

Action	Script	Impact
Correction dim_pays	fix_dim_pays.py	163 capitales + 165 coordonnees GPS
Export final	03_nettoyage_fusion.py	master_clean.csv — 0 NULL sur colonnes cles

7.2 Resultat Final Apres Nettoyage


- master_clean.csv : 1 222 lignes x 22 colonnes
- ZERO valeur manquante sur les 15 colonnes numeriques cles
- 169 pays couverts sur 10 annees (2015-2024)
- Score d'attractivite calcule pour les 1 222 combinaisons pays-annee

8. Analyse Exploratoire Post-Nettoyage (EDA 2)

8.1 Statistiques Descriptives Cles


Indicateur	Moyenne	Mediane	Min	Max	Ecart-type
Score bonheur	5,47	5,30	2,37	7,89	1,12
PIB/habitant (USD)	18 053	7 105	232	142 855	22 140
Esperance de vie	63,1	62,9	52,8	66,0	1,8
Taux chomage (%)	7,2	5,8	0,1	33,6	5,9
Score attractivite	0,53	0,52	0,11	0,90	0,15
Liberte	0,76	0,79	0,26	1,00	0,15
Corruption	0,75	0,79	0,04	0,97	0,19

8.2 Top 15 Pays les Plus Heureux




Les pays nordiques dominent systématiquement le classement : Finland, Denmark, Iceland, Norway, Switzerland. Ces pays combinent un PIB élevé, une liberté de choix maximale, un soutien social fort et une très faible perception de la corruption.

8.3 Matrice de Correlations




Les corrélations les plus fortes avec le score de bonheur sont : le soutien social ($r=0,78$), la liberté ($r=0,71$), le PIB log ($r=0,68$) et la corruption négative ($r=-0,65$). Ces résultats guident le choix des indicateurs pour le clustering.

8.4 Relation PIB vs Bonheur



La relation entre le PIB par habitant et le bonheur est forte sur échelle logarithmique, confirmant la loi de saturation : l'argent contribue au bonheur jusqu'à un certain seuil, après lequel les gains marginaux diminuent.

8.5 Evolution Temporelle par Region



L'Europe et l'Amérique du Nord maintiennent les scores les plus élevés. L'Afrique Sub-Saharienne et l'Asie du Sud présentent les scores les plus bas mais montrent une légère progression sur la période.

9. Analyse Statistique — Tests et Resultats

9.1 Test de Normalite — Shapiro-Wilk

Avant tout test parametrique, la normalite des distributions a ete verifiee sur un echantillon de 500 observations.

Variable	Stat. W	p-value	Conclusion
Score de bonheur	A completer apres execution	< 0,05	Non normale — tests non parametriques recommandes
PIB par habitant	A completer apres execution	< 0,05	Non normale — distribution log-asymetrique

happiness_score:
 Statistique W = 0.9840
 p-value = 0.0000
 Conclusion : Distribution NON normale ($\alpha=0.05$)

gdp_per_capita:
 Statistique W = 0.7380
 p-value = 0.0000
 Conclusion : Distribution NON normale ($\alpha=0.05$)

9.2 Test ANOVA — Bonheur par Region

H0 : Le bonheur moyen est identique dans toutes les regions du monde.

H1 : Au moins une region presente un bonheur moyen significativement different.

Test	F-statistique	p-value	Conclusion
ANOVA une voie	A completer	< 0,05	H0 rejetee — difference significative entre regions

Boxplot grouped by region

Distribution du bonheur par région

ANOVA F=196.09, p=0.0000

Score de bonheur

Région

9.3 Test Kruskal-Wallis — Bonheur par Niveau de Revenu

Test non parametrique (ne suppose pas la normalite). H_0 : la distribution du bonheur est identique entre les niveaux de revenu.

Test	H-statistique	p-value	Conclusion
Kruskal-Wallis	A completer	< 0,05	Les pays riches sont significativement plus heureux


H-statistique = 708.6773

p-value = 0.000000

✓ **RÉSULTAT** : Différence significative de bonheur selon le niveau de revenu
 → Les pays riches sont significativement plus heureux ($p < 0.05$)

9.4 Correlation de Pearson — PIB vs Bonheur

Correlation	Coeff. r	R2	p-value	Interpretation
Log(PIB) vs Bonheur	A completer	A completer	< 0,05	Correlation significative — PIB explique ~X% du bonheur



9.5 Test T — Impact Covid sur le Bonheur

Periode	Moyenne bonheur	n observations
Pre-Covid 2015-2019	5,47	A verifier
Post-Covid 2020-2024	5,59	A verifier
Difference (Impact Covid)	+0,11	Leger mieux post-covid

Interpretation : contrairement aux attentes, le score moyen de bonheur mondial a legerement augmente apres le Covid. Cela peut s'expliquer par la resilience sociale, le renforcement des liens familiaux et les aides gouvernementales massives deployees dans les pays riches.

10. Clustering K-Means — Machine Learning Non Supervise


10.1 Principe et Justification

Le clustering K-Means est un algorithme de Machine Learning non supervise qui regroupe automatiquement les pays en clusters selon leur similarite sur 8 indicateurs, sans etiquettes predefinies. Contrairement a une classification supervisee, K-Means decouvre les structures naturelles dans les donnees.

10.2 Variables Utilisees

Variable	Justification du choix
PIB par habitant	Indicateur principal de richesse economique
Score de bonheur	Mesure subjective de la qualite de vie
Esperance de vie	Proxy de la qualite du systeme de sante
Liberte de choix	Indicateur de gouvernance et de democratie
Corruption	Proxy de la qualite institutionnelle
Soutien social	Indicateur de cohesion sociale
Inflation	Stabilite macroeconomique
Croissance PIB	Dynamisme economique

10.3 Choix du Nombre de Clusters




La methode Elbow et le score de Silhouette indiquent k=2 comme optimal (score Silhouette = 0,37). Nous avons force k=4 pour une segmentation plus fine et analytiquement utile, acceptable car les scores restent coherents.

10.4 Description des 4 Clusters

Cluster	Nom attribue	Caracteristiques principales	Exemples de pays
0	Pays tres attractifs	PIB > 40 000 USD, Bonheur > 7, Corruption < 0,3	Finland, Denmark, Singapore, Norway, Switzerland
1	Pays émergents dynamiques	PIB moyen, forte croissance, bonheur modere	China, Brazil, Mexico, Turkey, Colombia
2	Pays en developpement	PIB faible-moyen, bonheur 4-5, en progression	India, Morocco, Egypt, Vietnam, Ghana
3	Pays en grande difficulté	PIB < 1 000 USD, Bonheur < 3,5, forte corruption	Afghanistan, Burundi, Chad, CAR, Yemen


10.5 Visualisation PCA



Les deux premières composantes principales expliquent 71,2% de la variance totale, ce qui permet une visualisation 2D fidèlement représentative de la structure multidimensionnelle des données.

11. Dashboard Power BI — Les 4 Pages

11.1 Modele de Donnees Power BI




Le modele Power BI reproduit fidelement le schema en etoile PostgreSQL. 4 relations ont ete creees avec cardinalite Un-a-Plusieurs depuis les dimensions vers la table de faits. Les 4 vues analytiques sont chargees en parallele comme tables autonomes.

11.2 Mesures DAX Crees

Mesure DAX	Formule simplifiee	Utilisation
PIB_Moyen	AVERAGE(fact_indicateurs[PIB_par_habitant])	Carte KPI Page 1
Attractivite_Moyenne	AVERAGE(fact_indicateurs[Score_attractivite])	Carte KPI Page 1
Croissance_Moyenne	AVERAGE(fact_indicateurs[Croissance_PIB])	Carte KPI Page 1
Bonheur_Moyen	AVERAGE(fact_indicateurs[Score_bonheur])	Toutes les pages
Pays_Plus_Heureux	FIRSTNONBLANK(TOPN(1,...))	Carte KPI Page 2
Liberte_Moyenne	AVERAGE(fact_indicateurs[Liberte])	Pages 2 et 3
Chomage_Moyen_Corrige	AVERAGEX(FILTER(...NOT ISBLANK...),...)	Page 3
Alphabetisation_Moyenne	ROUND(AVERAGE(...))	Page 3
Bonheur_PreCovid	CALCULATE(AVG, Annee<=2019)	Page 4
Bonheur_PostCovid	CALCULATE(AVG, Annee>=2020)	Page 4

Mesure DAX	Formule simplifiée	Utilisation
Impact_Covid	Bonheur_PostCovid - Bonheur_PreCovid	Carte KPI Page 4
Nb_Pays	DISTINCTCOUNT(Code_pays)	Toutes les pages


11.3 Page 1 — Tableau de Bord Investisseurs



Cette page est dédiée aux investisseurs qui souhaitent identifier les pays économiquement les plus attractifs. Elle présente le PIB moyen mondial (18 053 USD), le score d'attractivité moyen (0,53), la croissance économique moyenne (2,77%) et le nombre de pays analysés (169). Le Top 10 des pays les plus attractifs est dominé par les pays nordiques et Singapour. La carte mondiale visualise la répartition géographique du PIB par habitant.

- Visuels : 4 cartes KPI + bar chart Top 10 attractivité + scatter PIB vs croissance + carte mondiale PIB + slicers année et région


11.4 Page 2 — Qualite de Vie et Bonheur



Cette page aide les particuliers a choisir leur pays d'installation selon la qualite de vie. Le Finland est identifie comme pays le plus heureux (score 7,84), avec un bonheur moyen mondial de 5,53 et un impact Covid positif de +0,11. Le scatter liberte vs bonheur montre une correlation claire entre liberte de choix et satisfaction de vie.

- Visuels : 4 cartes KPI + bar chart Top 15 pays heureux + scatter liberte vs bonheur + carte mondiale bonheur + slicer annee et region


11.5 Page 3 — Mobilité Internationale Entreprises RH



Cette page aide les entreprises à choisir les meilleurs pays pour la mobilité de leurs employés. L'espérance de vie mondiale est de 63,2 ans, le taux de chômage moyen de 8%, la liberté moyenne de 0,79. Le graphique en anneau montre que 34,5% des pays sont à haut revenu. Les courbes d'évolution du chômage permettent d'identifier les régions les plus stables économiquement.

- Visuels : 4 cartes KPI + donut niveau de revenu + courbes chômage par région + barres espérance de vie/alphabétisation + tableau comparatif + slicers

11.6 Page 4 — Analyses Statistiques et Tendances



Cette page est dédiée aux analystes data. Elle présente l'impact Covid sur le bonheur (avant: 5,47, après: 5,59, impact: +0,11), la corrélation PIB vs bonheur, la répartition de la population mondiale par pays colorée par bonheur (treemap), et la contribution de chaque région au bonheur mondial (cascade). Le slicer Pre/Post Covid permet des comparaisons dynamiques.

- Visuels : 3 cartes KPI + courbes temporelles + scatter PIB vs bonheur + barres groupées pre/post covid + treemap population + cascade regions + slicers période et année

12. Resultats et Insights Cles

12.1 Principaux Resultats

Insight	Observation	Donnees supports
Dominance nordique	Les pays nordiques dominent le bonheur depuis 2015	Finland 7,84 ; Denmark 7,62 ; Iceland 7,55
Correlation PIB-Bonheur	Forte correlation log-lineaire entre PIB et bonheur	$r = \sim 0,7$; $R^2 = \sim 0,49$
Impact Covid positif	Le bonheur mondial a légèrement augmente post-covid	5,47 pre -> 5,59 post = +0,11

Insight	Observation	Donnees supports
Ecart regional	Ecart de 3,5 points entre Europe et Afrique Sub-Saharienne	Europe ~6,5 ; Afrique ~4,0
Corruption-Bonheur	Forte correlation negative corruption/bonheur	$r = -0,65$ (Spearman)
Saturation PIB	Au-dela de 50 000 USD/hab, le bonheur plafonne	Visible sur le scatter log PIB vs bonheur
Clustering	4 groupes naturels de pays identifiés par K-Means	Silhouette = 0,37 ; PCA 71,2% variance

12.2 Reponse a la Problematique

Les pays combinant les meilleures performances économiques ET qualite de vie sont : Finland, Denmark, Iceland, Norway, Switzerland, Singapore, Ireland et New Zealand. Ces pays presentent un PIB par habitant superieur a 45 000 USD, un score de bonheur superieur a 7/10, une corruption tres faible ($< 0,3$) et une liberte de choix elevee ($> 0,9$).

Pour l'investissement pur axe sur la croissance, les pays émergents comme l'Inde, le Vietnam et l'Ethiopie offrent des opportunités complémentaires avec des taux de croissance supérieurs a 6% par an, malgré des scores de bonheur plus modestes.

13. Limites du Projet et Ameliorations Futures

13.1 Limites Identifiees

Limite	Description	Impact	Priorite amelioration
Cout de la vie absent	Indice Numbeo non integre — API payante	Moyen — manque pour les migrants	Haute
WHR incomplet	Maroc et autres pays absents certaines annees	Faible — 157/169 pays couverts	Moyenne
Chomage partiel	13% de valeurs manquantes micro-territoires	Faible — non comparable	Faible
Donnees imputees	Inflation 2015 et esperance vie par mediane	Faible — tendances preservees	Faible
Pas de prediction	Pipeline descriptif uniquement	Moyen — pas d'anticipation	Haute

13.2 Améliorations Futures Proposées

1. Intégrer l'indice de coût de la vie Numbeo pour une analyse complète pour les particuliers et migrants
2. Implémenter un modèle prédictif (régression, Random Forest) pour anticiper l'évolution du bonheur
3. Automatiser le pipeline ETL avec Apache Airflow pour des mises à jour mensuelles automatiques
4. Créer une application web interactive avec Streamlit ou Dash pour un accès grand public
5. Intégrer l'indice Global Peace Index (GPI) comme indicateur de sécurité
6. Ajouter des données climatiques pour affiner les recommandations pour les particuliers

14. Conclusion

Ce projet fil rouge a permis de construire un pipeline de data analyse complet et professionnel, allant de la collecte automatisee de donnees via des APIs jusqu'a la visualisation interactive dans Power BI, en passant par une base de donnees PostgreSQL structuree en schema en etoile et une analyse statistique rigoureuse.

La problematique initiale — identifier objectivement les pays les plus attractifs pour investir ou vivre — a ete traitee de maniere systematique et evidence-based. Les resultats confirment que les pays nordiques offrent la combinaison optimale de richesse economique et qualite de vie, tandis que les economies emergentes d'Asie offrent des opportunités de croissance significatives pour les investisseurs.

En tant qu'apprenante en Data Analyse, ce projet m'a permis de maitriser l'ensemble de la chaine de valeur de la donnee : collecte API, ETL Python, modelisation relationnelle, tests statistiques, Machine Learning non supervise, et visualisation interactive. La methodologie CRISP-DM a guide chaque etape, assurant la rigueur et la reproductibilite des analyses.

Ce travail constitue une base solide extensible avec de nouvelles sources de donnees, des modeles predictifs et une automatisation complete du pipeline.

— *Fin du Rapport* —

Annexes

Annexe A — Liens du Projet

Ressource	Lien
GitHub — Code source	https://github.com/hajarmamdouh/fil-rouge-investissement
Jira — Gestion de projet	https://mamdouhhajar66.atlassian.net/jira/software/projects/ACDPPELELQD/boards/34
Confluence — Documentation	https://mamdouhhajar66-1771237842656.atlassian.net/wiki/x/yAAH
Cahier des charges	https://github.com/hajarmamdouh/fil-rouge-investissement/blob/main/cahier%20des%20charges.pdf

Annexe B — Technologies et Versions

Technologie	Version	Licence	Utilisation principale
Python	3.14	Open Source	Scripts ETL et analyse
Pandas	2.x	BSD	Manipulation donnees
NumPy	1.x	BSD	Calculs numeriques
Scikit-learn	1.x	BSD	K-Means, PCA, normalisation
Scipy	1.x	BSD	Tests statistiques ANOVA, Pearson
Matplotlib / Seaborn	3.x / 0.12.x	BSD	Graphiques EDA
PostgreSQL	18	Open Source	Base de donnees relationnelle
SQLAlchemy	2.x	MIT	ORM Python-PostgreSQL
wbdata	0.3.x	MIT	Acces API World Bank
Power BI Desktop	Latest	Microsoft	Dashboard interactif
Git / GitHub	Latest	Open Source	Versioning code
Jira / Confluence	Cloud	Atlassian	Gestion projet / Documentation

Annexe C — Glossaire

Terme	Définition
PIB	Produit Interieur Brut — valeur totale des biens et services produits dans un pays en une année
RNB	Revenu National Brut — comme le PIB mais inclut les revenus des citoyens à l'étranger
WHR	World Happiness Report — rapport annuel ONU sur le bonheur mondial (sondages Gallup)

Terme	Definition
ETL	Extract Transform Load — pipeline de donnees en 3 etapes : extraction, transformation, chargement
Schema en etoile	Modele Data Warehouse avec une table de faits centrale et des tables de dimensions
K-Means	Algorithme de clustering qui regroupe les donnees en k groupes homogenes
PCA	Principal Component Analysis — reduction de dimensions pour visualisation multidimensionnelle
ANOVA	Analysis of Variance — test statistique pour comparer les moyennes de plusieurs groupes
Silhouette	Mesure de qualite d'un clustering (entre -1 et 1, 1 = clusters parfaitement separees)
ISO3	Code pays standard a 3 lettres de l'ISO (ex: FRA=France, MAR=Maroc, USA=Etats-Unis)
DAX	Data Analysis Expressions — langage de formules Power BI pour les mesures et colonnes calculees
CRISP-DM	Cross-Industry Standard Process for Data Mining — methodologie standard d'analyse de donnees